

Retrieval Augmented Generation

Wie externes Wissen in Sprachmodelle kommt
Jonas Konzack, Sebastian Kleber



01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Das Problem

Definition

Was ist RAG

Das Problem

Unternehmen:

- Kostengünstig

PrivateGPT:

- Lokal laufen

Daten:

- Müssen representiert werden




Abbildung: Einleitendes Beispiel

Was ist RAG

Überblick




Abbildung: High Level View

01 | Was ist RAG?

02 | **Technische Erklärung**

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Embedding Generierung

Similarity Search

Request Workflow




Abbildung: Embedding




Abbildung: Similarity Search




Abbildung: Detailed View

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Gibt es noch Fragen?

Vielen Dank!

Jonas Konzack, Sebastian Kleber

