

Retrieval Augmented Generation

Wie externes Wissen in Sprachmodelle kommt
Jonas Konzack, Sebastian Kleber



01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Das Problem

Definition

Was ist RAG

Das Problem

Unternehmen:

- Kostengünstig

PrivateGPT:

- Lokal laufen

Daten:

- Müssen representiert werden




Abbildung: Einleitendes Beispiel

Was ist RAG

Überblick




Abbildung: High Level View

01 | Was ist RAG?

02 | **Technische Erklärung**

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Embedding Generierung

Similarity Search

Request Workflow




Abbildung: Embedding




Abbildung: Similarity Search




Abbildung: Detailed View

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Anwendungsbeispiel - Pinterest

RAG for data tables selection




Abbildung: Pinterest - RAG für die Tabellen Auswahl

¹Source: <https://medium.com/pinterest-engineering/how-we-built-text-to-sql-at-pinterest-30bad30dabff>

Anwendungsbeispiel - DoorDash

RAG for Delivery support chatbot




Abbildung: DoorDash - RAG als Teil des Support-Systems

²Source: <https://careersatdoordash.com/blog/large-language-modules-based-dasher-support-automation/>

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiel

04 | Moderne Ansätze

Moderne Ansätze

Klassisches RAG vs. Modernes / Agentic RAG

Klassisches RAG

- Fester Ablauf:
Anfrage → Retrieval → Antwort
- Meist ein Retriever und eine Wissensquelle
- Vektorbasierte Suche nach ähnlichen Text-Chunks
- Kontext wird direkt in den Prompt eingefügt
- Gut für einfache, klar abgegrenzte Wissensfragen

Modernes / Agentic RAG

- Dynamischer Ablauf mit Planung und Routing
- Mehrere Quellen: Vektorindex, SQL, APIs, Graphen
- Query-Rewriting, Hybrid Search und Re-Ranking
- Validierung, Guardrails und ggf. erneute Suche
- Gut für komplexe Workflows und Produktionssysteme

Fragen?

Gibt es noch Fragen?

