

Retrieval Augmented Generation

Wie externes Wissen in Sprachmodelle kommt
Jonas Konzack, Sebastian Kleber



01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiele

04 | Moderne Ansätze

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiele

04 | Moderne Ansätze

Das Problem

Definition

Was ist RAG

Das Problem

Unternehmen:

- Kostengünstig
- Aktualität

PrivateGPT:

- Lokal laufen
- keine Halluzinationen

Daten:

- Müssen repräsentiert werden
- ergänzbar




Abbildung: Einleitendes Beispiel

Was ist RAG

Überblick




Abbildung: High Level View

¹further readings: <https://www.iese.fraunhofer.de/blog/retrieval-augmented-generation-rag/>

01 | Was ist RAG?

02 | **Technische Erklärung**

03 | Anwendungsbeispiele

04 | Moderne Ansätze

Embedding Generierung

Similarity Search

Request Workflow




Abbildung: Embedding

¹further readings: [https://en.wikipedia.org/wiki/Embedding_\(machine_learning\)](https://en.wikipedia.org/wiki/Embedding_(machine_learning))




Abbildung: Similarity Search




Abbildung: Detailed View

¹further readings: <https://www.pinecone.io/learn/retrieval-augmented-generation/>

01 | Was ist RAG?

02 | Technische Erklärung

03 | **Anwendungsbeispiele**

04 | Moderne Ansätze

Pinterest

DoorDash

Anwendungsbeispiel - Pinterest

RAG zur Tabellenauswahl




Abbildung: Pinterest - RAG zur Tabellenauswahl

¹Source: How we built Text-to-SQL at Pinterest

Anwendungsbeispiel - DoorDash

RAG für den Delivery support chatbot




Abbildung: DoorDash - RAG als Teil des Support-Systems

²Source: Path to high-quality LLM-based Dasher support automation

01 | Was ist RAG?

02 | Technische Erklärung

03 | Anwendungsbeispiele

04 | **Moderne Ansätze**

Klassisches vs. modernes RAG

Klassisches RAG

- Fester Ablauf:
Anfrage → Retrieval → Antwort
- Meist ein Retriever und eine Wissensquelle
- Vektorbasierte Suche nach ähnlichen Text-Chunks
- Kontext wird direkt in den Prompt eingefügt
- Gut für einfache, klar abgegrenzte Wissensfragen

Modernes / Agentic RAG

- Dynamischer Ablauf mit Planung und Routing
- Mehrere Quellen: Vektorindex, SQL, APIs, Graphen, Memory
- Query-Rewriting, Hybrid Search und Re-Ranking
- Validierung, Guardrails und ggf. erneute Suche
- Gut für komplexe Workflows und Produktionssysteme

Gibt es noch Fragen?

Vielen Dank!

Jonas Konzack, Sebastian Kleber

